

제조업용 결함 검출 AI SaaS

기본설계서 / 시스템 사양서 (추가 정리판)

문서명: 제조업용 결함 검출 AI SaaS 기본설계서

버전: v1.1

작성일: 2026-03-24

작성자: 신재원

1. 시스템 개요

본 시스템은 제조 현장의 검사 이미지를 입력으로 받아, CNN 기반 머신러닝 모델을 통해 제품의 정상/결함 여부를 판정하는 **결함 검출 AI 시스템**이다.

또한 본 시스템은 단순한 추론 API에 그치지 않고, 사용자 인증, 추론 이력 관리, 로그 저장, 관리자 리뷰 기능을 포함하는 **SaaS형 결함 검사 지원 시스템**으로 설계한다.

본 프로젝트는 결함 데이터가 적은 실제 운영 환경의 특성을 고려하여, 단순히 Accuracy를 높이는 것이 아니라 **결함 누락(False Negative)**을 줄이는 것을 최우선 방침으로 한다.

따라서 모델 평가에서는 **Recall(재현율)**을 주요 지표로 사용하며, 시스템 전체적으로도 신뢰 가능한 검사 지원 기반을 구축하는 것을 목표로 한다.

2. 배경

제조업의 외관 검사 및 품질 검사 공정에서는 불량품을 정상품으로 잘못 판정하는 일이 품질 사고, 출하 불량, 고객 클레임, 회수 비용, 안전 문제로 이어질 수 있는 중대한 리스크가 된다.

반면 실제 검사 데이터는 정상 샘플 수가 훨씬 많고 결함 샘플은 매우 적은 경우가 많아, 데이터 셋에 심각한 **클래스 불균형**이 존재한다.

이러한 조건에서는 모델이 대부분을 정상으로 예측하더라도 높은 Accuracy를 보일 수 있으며, Accuracy만으로는 시스템의 신뢰성을 충분히 판단할 수 없다.

따라서 본 프로젝트는 다음과 같은 관점에서 시스템을 재설계한다.

- 평가 지표를 Accuracy 중심에서 Recall 중심으로 전환한다
- Notebook 기반 실험 결과를 API / DB / UI를 갖춘 구조로 발전시킨다
- 추론 결과를 기록하여 오분류 및 저신뢰 케이스를 지속적으로 분석할 수 있도록 한다

- 향후에는 외부 AI 보조 기능(MCP 연계)을 통해 리뷰 지원 및 유사 사례 분석으로 확장 가능하도록 한다

3. 목적

본 시스템의 목적은 다음과 같다.

1. 제조 검사 이미지에 대해 결함 유무를 자동 판정한다
2. 심각한 클래스 불균형 환경에서도 신뢰할 수 있는 평가 전략을 적용한다
3. 결함 누락을 최소화하기 위해 Recall을 주요 평가 지표로 사용한다
4. 머신러닝 모델을 FastAPI 기반 추론 API로 제공한다
5. 인증, 이력, 로그, 리뷰 기능을 포함한 SaaS 구조로 확장한다
6. 향후 MCP 연계를 통해 저신뢰 케이스 보조 분석 및 운영 리포트 생성이 가능한 기반을 마련한다

4. 적용 범위

4.1 대상 범위

본 시스템의 대상 범위는 다음과 같다.

- 검사 이미지 업로드
- 이미지 전처리
- 학습 완료된 CNN 모델을 이용한 추론
- 추론 결과의 API 응답
- 추론 이력 저장
- 사용자 인증
- 사용자별 이용 이력 관리
- 요청 로그 / 에러 로그 저장

- 관리자용 리뷰 대상 관리
- 향후 저신뢰 케이스 분석 지원

4.2 대상 외 범위

본 설계 시점에서 아래 항목은 범위 외로 한다.

- 자동 재학습의 완전 구현
- 결함 위치 검출(Object Detection / Segmentation)
- 다중 클래스 결함 분류
- 운영 환경용고가용성 클러스터 구성
- 완전한 MLOps 파이프라인 자동화

5. 전제 조건

- 입력 이미지는 학습 데이터와 동일하거나 유사한 도메인일 것
- 판정 대상은 이진 분류(normal / defect)로 한다
- 추론용 모델은 사전 학습 완료된 모델을 사용한다
- 백엔드는 FastAPI로 구현한다
- 프론트엔드는 React를 사용한다
- 추론 결과 및 관련 로그는 MySQL에 저장한다
- 향후 Docker화, AWS 배포, MCP 연계를 고려한 구조로 설계한다


6. 시스템 구성

6.1 전체 구성

구분	구성 요소	내용
Frontend	React (Vite)	이미지 업로드, 결과 표시, 이력 조회

구분	구성 요소	내용
Backend	FastAPI	인증, 추론 API, 로그 관리, 리뷰 기능
ML Model	TensorFlow / AutoKeras	결함 검출 추론
Database	MySQL	사용자, 이미지, 예측, 로그, 리뷰 정보 저장
Infra	Docker / AWS	컨테이너 실행 및 배포 기반
Future Extension	MCP 연계	외부 AI 기반 보조 분석 및 리포트 생성

6.2 시스템 구성도



7. 업무 요구사항

7.1 기본 업무 요구사항

- 사용자는 이미지를 업로드하여 결함 판정을 실행할 수 있어야 한다
- 시스템은 예측 라벨과 신뢰도를 반환할 수 있어야 한다
- 추론 결과는 이력으로 저장되어야 한다
- 사용자별로 업로드 이력을 조회할 수 있어야 한다

- 관리자는 저신뢰 케이스 또는 리뷰 대상 케이스를 확인할 수 있어야 한다

7.2 품질 요구사항

- 결함 누락을 최소화하는 평가 방침을 적용해야 한다
- 추론 결과의 근거가 되는 로그를 보관할 수 있어야 한다
- 오분류 및 실패 케이스를 분석할 수 있어야 한다
- 향후 개선을 위해 데이터 후보를 축적할 수 있어야 한다

8. 데이터셋 개요

본 프로젝트에서 사용하는 데이터셋은 정상 이미지와 결함 이미지로 구성된다.
데이터 분포는 다음과 같다.

분할 정상 결함

학습 1102 59

테스트 276 15

8.1 데이터상의 과제

- 결함 데이터 수가 적다
- 클래스 불균형이 매우 심하다
- Accuracy만으로는 실제 운영 리스크를 반영하기 어렵다
- Train / Test 간 유사 샘플이 존재할 가능성이 있다

따라서 본 시스템에서는 Recall을 주요 지표로 사용하고, Precision, F1 Score, Confusion Matrix, ROC Curve를 함께 활용한다.

9. 모델 설계

9.1 모델 개요

항목	내용
----	----

모델 종류	CNN Classifier
-------	----------------

구현 방식	AutoKeras ImageClassifier
-------	---------------------------

프레임워크	TensorFlow / AutoKeras
-------	------------------------

9.2 학습 설정

항목	내용
----	----

Loss Function	Binary Cross Entropy
---------------	----------------------

Validation Split	0.2
------------------	-----

Epochs	3
--------	---

9.3 전처리

항목	내용
----	----

리사이즈	256 × 256
------	-----------

정규화	[0,1]
-----	-------

색상 변환	RGB
-------	-----

9.4 라벨 정의

값 의미

0 normal

1 defect

10. 평가 방침

10.1 평가 전략

본 시스템에서는 제조 공정에서 가장 큰 실패가 **결함 누락**이므로, Recall을 주요 평가 지표로 사용한다.

Accuracy는 보조 지표로 활용하며, 단독으로 모델 채택 여부를 판단하지 않는다.

10.2 평가 지표

- Accuracy
- Precision
- Recall(주요 지표)
- F1 Score
- Confusion Matrix
- ROC Curve

10.3 평가 시 유의사항

다음 이유로 인해 현 시점의 평가 결과가 다소 낙관적으로 보일 가능성이 있다.

- 데이터셋 규모가 작다
- 결함 클래스 수가 극히 적다
- 이미지 분포 편향 가능성이 있다
- 외부 데이터셋으로는 아직 검증되지 않았다

향후 추가 검증 방침은 다음과 같다.

- Cross Validation
- 외부 데이터셋 평가
- Threshold Calibration
- Data Augmentation
- Class Weighting

11. 기능 사양

11.1 사용자 인증 기능

개요

사용자별 이미지 업로드 및 이력 관리를 위해 인증 기능을 제공한다.

기능 목록

- 회원가입
- 로그인
- JWT 발급 및 검증
- 인증된 사용자만 업로드 가능하도록 제어

목적

- 사용자 단위 데이터 관리
- 이용 이력 관리
- SaaS 형태의 기본 접근 제어 구현

11.2 헬스체크 기능

엔드포인트

Method Path 설명

GET /health API 동작 상태 확인

응답 예시

```
{  
  "status": "ok"  
}
```

11.3 결함 판정 기능

개요

업로드된 이미지에 대해 전처리 및 CNN 추론을 수행하여 판정 결과를 반환한다.

엔드포인트

Method Path 설명

POST /predict 이미지를 받아 추론 결과를 반환한다

요청

- Content-Type: multipart/form-data
- 파라미터: file

응답 예시

```
{  
  "image_name": "sample.jpg",  
  "prediction": "defect",  
  "confidence": 0.91  
}
```

처리 개요

1. 인증 상태를 확인한다
2. 이미지를 수신한다
3. 전처리를 수행한다
4. CNN 모델로 추론한다
5. 결과를 저장한다
6. 응답을 반환한다

예외 상황

- 미인증 접근
- 잘못된 파일 형식
- 빈 파일
- 전처리 실패
- 모델 로딩 실패

- 추론 실패
- DB 저장 실패

11.4 추론 이력 조회 기능

개요

사용자는 자신의 과거 추론 결과를 조회할 수 있다.

주요 용도

- 과거 판정 결과 확인
- 오판정 사례 재검토
- 모델 개선용 사례 추출

11.5 로그 관리 기능

개요

추론 API 이용 이력 및 장애 분석을 위해 각종 로그를 저장한다.

대상 로그

- 요청 로그
- 에러 로그
- 추론 결과 로그
- 관리자 리뷰 결과

목적

- 장애 원인 조사
- 실패 케이스 파악
- 지속 개선을 위한 데이터 축적

11.6 관리자 리뷰 기능

개요

저신뢰 또는 오분류 의심 케이스를 관리자가 확인할 수 있도록 리뷰 대상 관리 기능을 둔다.

예상 기능

- review_queue 등록
- pending / reviewed / rejected 상태 관리
- human_label 기록
- dataset candidate로 승격 관리

이 기능은 추론 시스템을 지속 개선형 구조로 발전시키기 위한 핵심 요소이다.

12. 추론 처리 흐름

사용자 로그인



이미지 업로드



POST /predict



이미지 전처리



CNN 추론



추론 결과 생성



predictions / logs / review 후보 저장



응답 반환

13. DB 설계

13.1 설계 방침

본 시스템은 단순히 prediction 저장에 그치지 않고, SaaS형 서비스로서의 이용 관리, 분석, 리뷰, 향후 재학습 후보 관리까지 고려한 DB 구조를 설계한다.

13.2 테이블 목록

테이블명	용도
users	사용자 관리
uploaded_images	업로드 이미지 관리
predictions	추론 결과 관리
request_logs	API 요청 로그
error_logs	에러 로그
review_queue	리뷰 대상 케이스 관리
dataset_candidates	재학습 후보 데이터 관리

13.3 주요 테이블 정의

users

컬럼명	내용
id	기본키
email	로그인 ID
password_hash	해시 처리된 비밀번호
role	user / admin
created_at	생성 일시

predictions

컬럼명	내용
id	기본키

컬럼명	내용
-----	----

image_id	대상 이미지 ID
----------	-----------

user_id	실행 사용자 ID
---------	-----------

label	예측 라벨
-------	-------

confidence	추론 신뢰도
------------	--------

status	추론 상태
--------	-------

created_at	등록 일시
------------	-------

review_queue

컬럼명	내용
-----	----

id	기본키
----	-----

prediction_id	대상 예측 ID
---------------	----------

review_status	pending / reviewed / rejected
---------------	-------------------------------

human_label	사람 검토 라벨
-------------	----------

created_at	등록 일시
------------	-------

13.4 확장 필드 후보

향후 AI 보조 분석을 고려하여 다음과 같은 항목을 추가할 수 있다.

- review_status
- human_label
- ai_review_summary
- ai_review_recommendation
- is_low_confidence
- is_dataset_candidate
- failure_reason

- similar_case_group

14. 프론트엔드 사양

14.1 개요

프론트엔드는 React로 구현하며, 사용자가 브라우저에서 직관적으로 이미지 업로드와 결과 확인을 수행할 수 있도록 한다.

14.2 주요 기능

- 로그인 화면
- 이미지 업로드 화면
- 추론 결과 표시
- 사용자별 이력 조회
- 관리자용 리뷰 대상 표시
- 향후 AI 분석 버튼 추가

14.3 화면 흐름

1. 사용자가 로그인한다
2. 이미지를 선택한다
3. Upload를 실행한다
4. 추론 결과를 표시한다
5. 필요 시 이력 화면 또는 리뷰 화면에서 확인한다

15. 비기능 요구사항

15.1 신뢰성

- 결함 누락을 줄이기 위한 평가 방침을 채택할 것
- 추론, 로그, 리뷰 결과를 저장할 것

- 장애 발생 시 추적 가능해야 할 것

15.2 유지보수성

- Router / Service / DB 처리를 분리할 것
- PredictionService / ReviewService / CaseQueryService / ReportService를 단계적으로 분리 가능하게 설계할 것
- 설정값을 외부화할 것

15.3 확장성

- JWT 인증 추가에 대응 가능할 것
- 관리자 리뷰 기능을 추가할 수 있을 것
- Docker화 및 AWS 배포에 대응 가능할 것
- MCP 연계를 위한 API / DB 확장이 가능할 것

15.4 운영성

- 로그 확인 절차를 정리할 수 있을 것
- 장애 확인 순서를 문서화할 수 있을 것
- 배포 절차를 README 등으로 남길 수 있을 것

16. 인프라 및 배포 방침

16.1 로컬 실행

- API 컨테이너화
- MySQL 컨테이너화
- docker-compose 등을 통한 일괄 실행

16.2 운영 배포

- AWS(예: EC2) 배포를 가정
- 환경 변수 관리

- 개발 / 운영 환경 분리
- health check 수행
- 실제 서버에서 Upload → Predict → DB 저장까지 연동 확인

16.3 저장 방침

- 이미지 저장소는 local 또는 S3를 검토
- 로그 저장 위치 및 확인 방법은 별도 운영 설계에서 정의

17. 향후 확장 방침

17.1 모델 측면

- Data Augmentation
- Class Weighting
- Threshold 최적화
- 대규모 데이터 기반 재검증
- 외부 데이터셋 평가

17.2 시스템 측면

- 이력 조회 기능 강화
- 관리자 리뷰 화면
- 실패 케이스 분리 저장
- 데이터셋 후보 관리
- 캐시 도입
- 비동기 처리 도입

17.3 MCP / 외부 AI 연계

향후에는 MCP를 통해 외부 AI가 다음 기능을 보조할 수 있는 구조를 상정한다.

- 저신뢰 케이스 설명

- 과거 유사 사례 검색
- 관리자 리뷰 보조
- 운영 리포트 생성
- 재학습 후보 제안

예상 MCP Tool 예시는 다음과 같다.

- predict_defect(image_id)
- get_prediction_result(case_id)
- list_low_confidence_cases(limit)
- get_case_detail(case_id)
- get_similar_cases(case_id)
- save_ai_review(case_id, summary, recommendation)

이는 기존 결함 검출 시스템을 대체하는 것이 아니라, 기존 시스템을 확장하는 보조 레이어로 위치시킨다.

18. 기술 스택

Backend

- Python
- FastAPI
- MySQL

ML / DL

- TensorFlow
- AutoKeras
- NumPy
- Pillow

Frontend

- React (Vite)

- Tailwind CSS
- JavaScript

Infra

- Docker
- AWS

Future Extension

- MCP
- External AI Assistant

19. 제약사항 및 과제

19.1 현재 과제

- 데이터셋 규모가 작다
- 클래스 불균형이 크다
- 임계값 조정이 충분하지 않다
- 도메인 외 이미지에 대한 일반화 성능이 검증되지 않았다
- Notebook 기반 실험에서 SaaS 구조로 이행 중이다

19.2 대응 방침

- 모델 평가의 엄격화
- 로그 축적 및 실패 분석
- DB / API / UI의 단계적 확장
- 배포와 운영을 포함한 시스템화
- 향후 AI 보조 분석 기반 추가

20. 요약

본 시스템은 제조업 결함 검출에서 **Accuracy** 중심 평가의 한계를 고려하여, **Recall** 중심으로 신뢰성을 확보하는 결함 검출 **AI SaaS**로 설계하는 것을 목표로 한다.

또한 단순한 머신러닝 모델 구현에 머무르지 않고, 인증, 이력 관리, 로그 저장, 리뷰 큐, 향후 MCP 연계까지 고려함으로써 실제 운영에 가까운 시스템 기반을 구축한다.